

3.3 最优回归设计

王正明 易泰河

系统工程学院 军事建模与仿真系

2019 年 12 月 20 日

引言

思考

将一幅画固定在墙上, 至少需要几颗钉子? 如果给三颗钉子, 应该如何钉? 给四颗呢?

例

假设消耗的能量 y 与跑步距离 x 存在指数关系:

$$y = A \exp\{Bx\}, \quad x \in [5\text{km}, 10\text{km}].$$

A 和 B 为待估计的参数. 设计试验以高效地得到 A 和 B , 并设计一次验证模型的跑步试验.

引言

思考

将一幅画固定在墙上, 至少需要几颗钉子? 如果给三颗钉子, 应该如何钉? 给四颗呢?

例

假设消耗的能量 y 与跑步距离 x 存在指数关系:

$$y = A \exp\{Bx\}, \quad x \in [5\text{km}, 10\text{km}].$$

A 和 B 为待估计的参数. 设计试验以高效地得到 A 和 B , 并设计一次验证模型的跑步试验.

引言

例 (称重问题)

用一架精度为 σ 的天平称 4 个不同的物体, 称重方案:

序号	左侧	右侧	差异
1	1 2 3 4	空	y_1
2	1 2	3 4	y_2
3	1 3	2 4	y_3
4	1 4	2 3	y_4

每一个物体的测量精度都能达到 $\sigma^2/4$. 能否找到一种精度更高的称重方案?

知识回顾

- 称 $\xi_n = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 为一个试验次数为 n 的精确设计, \mathbf{x}_i 为它的支撑点或谱点. ξ_n 的矩阵表示

$$D_{\xi_n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

- 离散设计: $\xi_k = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_k \\ p_1 & p_2 & \cdots & p_k \end{pmatrix}$.
- 称试验区域 \mathcal{X} 上的概率分布 ξ 为设计, 给定试验次数 n 后从 ξ 中抽取 n 个样本作为试验方案.
- 也称 ξ_n 为确定性设计, ξ_k 和 ξ 为近似设计.

知识回顾

- 线性回归模型: $y = \mathbf{f}^\top(\mathbf{x})\boldsymbol{\beta} + \varepsilon$.
- 线性模型 $\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$ 的参数估计:

$$\begin{cases} \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \\ \hat{\sigma}^2 = \frac{1}{n - m} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}). \end{cases}$$

- $\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$, 它的方差矩阵为 $\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$.
- 预测值 $\hat{y}(\mathbf{x}) = \mathbf{f}^\top(\mathbf{x})\hat{\boldsymbol{\beta}}$ 的方差为 $\sigma^2 \mathbf{f}^\top(\mathbf{x})(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{f}(\mathbf{x})$.
- 矩阵 $\mathbf{X}^\top \mathbf{X} = \sum_{i=1}^n \mathbf{f}(\mathbf{x}_i) \mathbf{f}^\top(\mathbf{x}_i)$ 决定参数估计和预测的精度.

3.3 最优回归设计

3.3.1 设计的信息矩阵

3.3.2 优良性准则

3.3.3 等价性定理

3.3.4 D 最优设计的迭代求解

线性回归模型 $y = \mathbf{f}(\mathbf{x})^\top \boldsymbol{\beta} + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ 中:

- 精确设计 $\xi_n = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 的信息矩阵定义为

$$\mathbf{M}(\xi_n) = \frac{1}{n} \mathbf{X}^\top \mathbf{X} = \frac{1}{n} \sum_{i=1}^n \mathbf{f}(\mathbf{x}_i) \mathbf{f}^\top(\mathbf{x}_i).$$

- 离散设计 $\xi_k = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_k \\ p_1 & p_2 & \cdots & p_k \end{pmatrix}$ 的信息矩阵定义为

$$\mathbf{M}(\xi_k) = \sum_{i=1}^k p_i \mathbf{f}(\mathbf{x}_i) \mathbf{f}^\top(\mathbf{x}_i).$$

线性回归模型 $y = \mathbf{f}(\mathbf{x})^\top \boldsymbol{\beta} + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ 中:

- 精确设计 $\xi_n = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 的信息矩阵定义为

$$\mathbf{M}(\xi_n) = \frac{1}{n} \mathbf{X}^\top \mathbf{X} = \frac{1}{n} \sum_{i=1}^n \mathbf{f}(\mathbf{x}_i) \mathbf{f}^\top(\mathbf{x}_i).$$

- 离散设计 $\xi_k = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_k \\ p_1 & p_2 & \cdots & p_k \end{pmatrix}$ 的信息矩阵定义为

$$\mathbf{M}(\xi_k) = \sum_{i=1}^k p_i \mathbf{f}(\mathbf{x}_i) \mathbf{f}^\top(\mathbf{x}_i).$$

定义 (设计的信息矩阵)

线性回归模型 $y = \mathbf{f}(\mathbf{x})^\top \boldsymbol{\beta} + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ 中, 称试验区域 \mathcal{X} 上的概率分布 ξ 为一个设计, 其信息矩阵定义为

$$\mathbf{M}(\xi) := \int_{\mathcal{X}} \mathbf{f}(\mathbf{x}) \mathbf{f}^\top(\mathbf{x}) d\xi,$$

称满足 $\det(\mathbf{M}(\xi)) \neq 0$ 的设计 ξ 为非奇异的.

- 一个好的设计应使 $\mathbf{M}(\xi)$ 达到 “最大” .

定义 (设计的信息矩阵)

线性回归模型 $y = \mathbf{f}(\mathbf{x})^\top \boldsymbol{\beta} + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$ 中, 称试验区域 \mathcal{X} 上的概率分布 ξ 为一个设计, 其信息矩阵定义为

$$\mathbf{M}(\xi) := \int_{\mathcal{X}} \mathbf{f}(\mathbf{x}) \mathbf{f}^\top(\mathbf{x}) d\xi,$$

称满足 $\det(\mathbf{M}(\xi)) \neq 0$ 的设计 ξ 为非奇异的.

- 一个好的设计应使 $\mathbf{M}(\xi)$ 达到 “最大” .

例 (一元一次线性回归)

设 $x \in [-1, 1]$, 求线性模型 $y = \beta_0 + \beta_1 x + \varepsilon$ 中精确设计 $\xi_n = \{x_1, x_2, \dots, x_n\}$ 和密度函数为 $p(x)$ 的设计 ξ 的信息矩阵.

- 精确设计 $\xi_n = \{x_1, x_2, \dots, x_n\}$ 的信息矩阵为

$$\begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_i \\ \frac{1}{n} \sum_{i=1}^n x_i & \frac{1}{n} \sum_{i=1}^n x_i^2 \end{bmatrix}.$$

- 密度函数为 $p(x)$ 的设计 ξ 的信息矩阵为

$$\begin{bmatrix} 1 & \int_{-1}^1 xp(x)dx \\ \int_{-1}^1 xp(x)dx & \int_{-1}^1 x^2 p(x)dx \end{bmatrix}.$$

例 (一元一次线性回归)

设 $x \in [-1, 1]$, 求线性模型 $y = \beta_0 + \beta_1 x + \varepsilon$ 中精确设计 $\xi_n = \{x_1, x_2, \dots, x_n\}$ 和密度函数为 $p(x)$ 的设计 ξ 的信息矩阵.

- 精确设计 $\xi_n = \{x_1, x_2, \dots, x_n\}$ 的信息矩阵为

$$\begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_i \\ \frac{1}{n} \sum_{i=1}^n x_i & \frac{1}{n} \sum_{i=1}^n x_i^2 \end{bmatrix}.$$

- 密度函数为 $p(x)$ 的设计 ξ 的信息矩阵为

$$\begin{bmatrix} 1 & \int_{-1}^1 x p(x) dx \\ \int_{-1}^1 x p(x) dx & \int_{-1}^1 x^2 p(x) dx \end{bmatrix}.$$

例 (二元一次线性回归)

设 $(x_1, x_2) \in [-1, 1]^2$, 讨论线性模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

中精确设计 ξ_n 和密度函数为 $p(x_1, x_2)$ 的设计 ξ 的信息矩阵.

$$\bullet \quad M(\xi_n) = \begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_{i1} & \frac{1}{n} \sum_{i=1}^n x_{i2} \\ \frac{1}{n} \sum_{i=1}^n x_{i1} & \frac{1}{n} \sum_{i=1}^n x_{i1}^2 & \frac{1}{n} \sum_{i=1}^n x_{i1} x_{i2} \\ \frac{1}{n} \sum_{i=1}^n x_{i2} & \frac{1}{n} \sum_{i=1}^n x_{i1} x_{i2} & \frac{1}{n} \sum_{i=1}^n x_{i2}^2 \end{bmatrix}$$

$$\bullet \quad M(\xi) = \begin{bmatrix} 1 & \int x_1 p(x_1, x_2) dx_1 dx_2 & \int x_2 p(x_1, x_2) dx_1 dx_2 \\ \int x_1 p(x_1, x_2) dx_1 dx_2 & \int x_1^2 p(x_1, x_2) dx_1 dx_2 & \int x_1 x_2 p(x_1, x_2) dx_1 dx_2 \\ \int x_2 p(x_1, x_2) dx_1 dx_2 & \int x_1 x_2 p(x_1, x_2) dx_1 dx_2 & \int x_2^2 p(x_1, x_2) dx_1 dx_2 \end{bmatrix}$$

例 (二元一次线性回归)

设 $(x_1, x_2) \in [-1, 1]^2$, 讨论线性模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

中精确设计 ξ_n 和密度函数为 $p(x_1, x_2)$ 的设计 ξ 的信息矩阵.

$$\bullet \quad M(\xi_n) = \begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_{i1} & \frac{1}{n} \sum_{i=1}^n x_{i2} \\ \frac{1}{n} \sum_{i=1}^n x_{i1} & \frac{1}{n} \sum_{i=1}^n x_{i1}^2 & \frac{1}{n} \sum_{i=1}^n x_{i1} x_{i2} \\ \frac{1}{n} \sum_{i=1}^n x_{i2} & \frac{1}{n} \sum_{i=1}^n x_{i1} x_{i2} & \frac{1}{n} \sum_{i=1}^n x_{i2}^2 \end{bmatrix}$$

$$\bullet \quad M(\xi) = \begin{bmatrix} 1 & \int x_1 p(x_1, x_2) dx_1 dx_2 & \int x_2 p(x_1, x_2) dx_1 dx_2 \\ \int x_1 p(x_1, x_2) dx_1 dx_2 & \int x_1^2 p(x_1, x_2) dx_1 dx_2 & \int x_1 x_2 p(x_1, x_2) dx_1 dx_2 \\ \int x_2 p(x_1, x_2) dx_1 dx_2 & \int x_1 x_2 p(x_1, x_2) dx_1 dx_2 & \int x_2^2 p(x_1, x_2) dx_1 dx_2 \end{bmatrix}$$

信息矩阵的性质

以 Ξ 表示所有设计组成的集合, Ξ_n 表示支撑点数为 n 的设计组成的集合, $\mathcal{M} = \{M(\xi) : \xi \in \Xi\}$:

- (1) 任意设计 ξ 的信息矩阵 $M(\xi)$ 都是非负定的;
- (2) Ξ 是凸集, \mathcal{M} 是一个闭凸集;
- (3) 如果 $n < m$, 则 $\det(M(\xi)) = 0$ 对任意 $\xi \in \Xi_n$ 都成立;
- (4) 任给 $\xi \in \Xi$, 存在 $\tilde{\xi} \in \Xi_n$, $n \leq m(m+1)/2 + 1$, 使得 $M(\xi) = M(\tilde{\xi})$.

3.3 最优回归设计

3.3.1 设计的信息矩阵

3.3.2 优良性准则

3.3.3 等价性定理

3.3.4 D 最优设计的迭代求解

定义 (最优设计)

设 $\Phi : \mathcal{M} \mapsto \mathbb{R}^+$ 满足 $M_1 \geq M_2 \Rightarrow \Phi(M_1) \leq \Phi(M_2)$. 若存在设计 $\xi^* \in \Xi$ 使得

$$\Phi(M(\xi^*)) = \inf \{ \Phi(M(\xi)) : \xi \in \Xi \},$$

则称 ξ^* 为 Φ 最优设计 (Φ -optimal design).

- 一般不能保证 $\Phi(M_1) \leq \Phi(M_2) \Rightarrow M_1 \geq M_2$, 因此选择的最优性准则 Φ 应具有一定的统计意义.
- 为简单起见, 记 $\Phi(\xi) = \Phi(M(\xi))$.

定义 (最优设计)

设 $\Phi : \mathcal{M} \mapsto \mathbb{R}^+$ 满足 $M_1 \geq M_2 \Rightarrow \Phi(M_1) \leq \Phi(M_2)$. 若存在设计 $\xi^* \in \Xi$ 使得

$$\Phi(M(\xi^*)) = \inf \{ \Phi(M(\xi)) : \xi \in \Xi \},$$

则称 ξ^* 为 **Φ 最优设计** (Φ -optimal design).

- 一般不能保证 $\Phi(M_1) \leq \Phi(M_2) \Rightarrow M_1 \geq M_2$, 因此选择的最优性准则 Φ 应具有一定的统计意义.
- 为简单起见, 记 $\Phi(\xi) = \Phi(M(\xi))$.

定义 (D 最优设计)

取 $\Phi_D(\xi) := \det(\mathbf{M}^{-1}(\xi))$, 称相应的最优设计为 D 最优设计 (D -optimal design).

给定置信概率 α , 最小二乘估计 $\hat{\beta}$ 的置信椭球体

$$\left\{ \beta \in \mathbb{R}^m : (\beta - \hat{\beta})^T \mathbf{M}^{-1}(\xi) (\beta - \hat{\beta}) \leq c_\alpha \right\}$$

的体积 $V(\xi) \propto [\det(\mathbf{M}^{-1}(\xi))]^{\frac{1}{2}}$, $\det(\mathbf{M}^{-1}(\xi))$ 越小 $\hat{\beta}$ 的精度越高.

定义 (D 最优设计)

取 $\Phi_D(\xi) := \det(\mathbf{M}^{-1}(\xi))$, 称相应的最优设计为 D 最优设计 (D -optimal design).

给定置信概率 α , 最小二乘估计 $\hat{\beta}$ 的置信椭球体

$$\left\{ \beta \in \mathbb{R}^m : (\beta - \hat{\beta})^T \mathbf{M}^{-1}(\xi) (\beta - \hat{\beta}) \leq c_\alpha \right\}$$

的体积 $V(\xi) \propto [\det(\mathbf{M}^{-1}(\xi))]^{\frac{1}{2}}$, $\det(\mathbf{M}^{-1}(\xi))$ 越小 $\hat{\beta}$ 的精度越高.

例 (一元一次线性回归)

设 $x \in [-1, 1]$, 限制在精确设计中求线性模型 $y = \beta_0 + \beta_1 x + \varepsilon$ 的 D 最优设计.

- 信息矩阵

$$M(\xi_n) = \frac{1}{n} \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix}$$

的行列式为 $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.

- 若试验次数 $n = 2$, 则 D 最优设计为 $\xi_2 = \{-1, 1\}$.
- 若试验次数 $n = 3$, 则 D 最优设计为 $\xi_3 = \{-1, -1, 1\}$ 或 $\{-1, 1, 1\}$.

例 (一元一次线性回归)

设 $x \in [-1, 1]$, 限制在精确设计中求线性模型 $y = \beta_0 + \beta_1 x + \varepsilon$ 的 D 最优设计.

- 信息矩阵

$$M(\xi_n) = \frac{1}{n} \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix}$$

的行列式为 $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.

- 若试验次数 $n = 2$, 则 D 最优设计为 $\xi_2 = \{-1, 1\}$.
- 若试验次数 $n = 3$, 则 D 最优设计为 $\xi_3 = \{-1, -1, 1\}$ 或 $\{-1, 1, 1\}$.

例 (称重问题)

用一架精度为 σ 的天平称 4 个不同的物体, 称重方案:

序号	左侧				右侧	差异
1	1	2	3	4	空	y_1
2		1	2		3 4	y_2
3		1	3		2 4	y_3
4		1	4		2 3	y_4

每一个物体的测量精度都能达到 $\sigma^2/4$. 能否找到一种精度更高的称重方案?

定义 (G 最优设计)

称 $d(\boldsymbol{x}, \xi) := \boldsymbol{f}^T(\boldsymbol{x}) \boldsymbol{M}^{-1}(\xi) \boldsymbol{f}(\boldsymbol{x})$ 为设计 ξ 的**标准化方差**, 称

$$\Phi_G(\xi) := \sup \{ d(\boldsymbol{x}, \xi) : \boldsymbol{x} \in \mathcal{X} \}$$

为 **G 最优准则**, 相应的最优设计称为 **G 最优设计**.

点 $\boldsymbol{x} \in \mathcal{X}$ 处的响应预测值 $\hat{y}(\boldsymbol{x}) = \boldsymbol{f}^T(\boldsymbol{x}) \hat{\beta}$ 的方差

$$\text{Var}(\hat{y}(\boldsymbol{x})) = \frac{\sigma^2}{n} \boldsymbol{f}^T(\boldsymbol{x}) \boldsymbol{M}^{-1}(\xi) \boldsymbol{f}(\boldsymbol{x}).$$

G 最优设计使得模型的最大预测方差达到最小.

定义 (G 最优设计)

称 $d(\boldsymbol{x}, \xi) := \boldsymbol{f}^T(\boldsymbol{x}) \boldsymbol{M}^{-1}(\xi) \boldsymbol{f}(\boldsymbol{x})$ 为设计 ξ 的**标准化方差**, 称

$$\Phi_G(\xi) := \sup \{ d(\boldsymbol{x}, \xi) : \boldsymbol{x} \in \mathcal{X} \}$$

为 **G 最优准则**, 相应的最优设计称为 **G 最优设计**.

点 $\boldsymbol{x} \in \mathcal{X}$ 处的响应预测值 $\hat{y}(\boldsymbol{x}) = \boldsymbol{f}^T(\boldsymbol{x}) \hat{\beta}$ 的方差

$$\text{Var}(\hat{y}(\boldsymbol{x})) = \frac{\sigma^2}{n} \boldsymbol{f}^T(\boldsymbol{x}) \boldsymbol{M}^{-1}(\xi) \boldsymbol{f}(\boldsymbol{x}).$$

G 最优设计使得模型的最大预测方差达到最小.

- 取向量 $\mathbf{c} \in \mathbb{R}^m$, 称 $\Phi_C(\xi) := \mathbf{c}^T \mathbf{M}^{-1}(\xi) \mathbf{c}$ 为 **C 最优准则**, 它使得参数线性组合 $\mathbf{c}^T \boldsymbol{\beta}$ 的最优无偏估计的方差达到最小.
- 称 $\Phi_A(\xi) := \text{tr}\{\mathbf{M}^{-1}(\xi)\}$ 为 **A 准则** 或 **MV 准则**, 它使参数估计的方差之和最小.
- 记 $\lambda_{\min}(\mathbf{M}(\xi))$ 为矩阵 $\mathbf{M}(\xi)$ 的特征值的最小值, 称 $\Phi_E(\xi) := \lambda_{\min}^{-1}(\mathbf{M}(\xi))$ 为 **E 准则**, 该准则使置信椭球体的最长轴最小.

- 取向量 $\mathbf{c} \in \mathbb{R}^m$, 称 $\Phi_C(\xi) := \mathbf{c}^T \mathbf{M}^{-1}(\xi) \mathbf{c}$ 为 **C 最优准则**, 它使得参数线性组合 $\mathbf{c}^T \boldsymbol{\beta}$ 的最优无偏估计的方差达到最小.
- 称 $\Phi_A(\xi) := \text{tr}\{\mathbf{M}^{-1}(\xi)\}$ 为 **A 准则** 或 **MV 准则**, 它使参数估计的方差之和最小.
- 记 $\lambda_{\min}(\mathbf{M}(\xi))$ 为矩阵 $\mathbf{M}(\xi)$ 的特征值的最小值, 称 $\Phi_E(\xi) := \lambda_{\min}^{-1}(\mathbf{M}(\xi))$ 为 **E 准则**, 该准则使置信椭球体的最长轴最小.

- 取向量 $\mathbf{c} \in \mathbb{R}^m$, 称 $\Phi_C(\xi) := \mathbf{c}^T \mathbf{M}^{-1}(\xi) \mathbf{c}$ 为 **C 最优准则**, 它使得参数线性组合 $\mathbf{c}^T \boldsymbol{\beta}$ 的最优无偏估计的方差达到最小.
- 称 $\Phi_A(\xi) := \text{tr}\{\mathbf{M}^{-1}(\xi)\}$ 为 **A 准则** 或 **MV 准则**, 它使参数估计的方差之和最小.
- 记 $\lambda_{\min}(\mathbf{M}(\xi))$ 为矩阵 $\mathbf{M}(\xi)$ 的特征值的最小值, 称 $\Phi_E(\xi) := \lambda_{\min}^{-1}(\mathbf{M}(\xi))$ 为 **E 准则**, 该准则使置信椭球体的最长轴最小.

例 (一元一次线性回归)

$x \in [-1, 1]$, 讨论线性模型 $y = \beta_0 + \beta_1 x + \varepsilon$ 的只做两次试验的 A 、 G 、 C 以及 E 最优设计.

例 (一元多项式回归)

一元线性回归模型 $y = \beta_0 + \beta_1 x + \cdots + \beta_d x^d + \varepsilon$ 的 D -最优设计的支撑点是方程

$$(1 - x^2) \frac{dP_d(x)}{dx} = 0$$

的根, 即由两个端点 -1 和 1 , 以及 d 阶 Legendre 多项式的导数的根组成, 一共 $d+1$ 个点. Legendre 多项式定义如下:

$$\begin{cases} P_0(x) = 1, & P_1(x) = x, \\ (d+1)P_{d+1}(x) = (2d+1)xP_d(x) - dP_{d-1}(x). \end{cases}$$

例 (一元多项式回归 Cont.)

当 $d = 1, 2, \dots, 6$ 时, 一元线性回归模型

$$y = \beta_0 + \beta_1 x + \dots + \beta_d x^d + \varepsilon$$

的 D -最优设计的支撑点:

d	x_1	x_2	x_3	x_4	x_5	x_6	x_7
1	-1						1
2	-1			0			1
3	-1		-0.4472		0.4472		1
4	-1		-0.6547	0	0.6547		1
5	-1	-0.7651	-0.2852		0.2852	0.7651	1
6	-1	-0.8302	-0.4688	0	0.4688	0.8302	1

例 (多元一次线性回归模型)

考虑 p 个因子的一阶线性回归模型

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon.$$

(Heiligers, 1992) 和 (Chen, 2003) 指出, 如果试验区域 \mathcal{X} 为 \mathbb{R}^p 中的凸集, 则多元线性回归模型的离散或精确 D 最优设计的设计点都在 \mathcal{X} 的顶点上.

由于超球体和超立方体都是凸集, 因此这两种试验区域的 D 最优设计点都在其顶点上. 构造离散或精确 D 最优设计时, 只需在全体顶点的集合中搜索即可.

例 (多元一次线性回归模型 cont.)

当试验区域为超球体 $\mathcal{X} = \left\{ \mathbf{x} \in \mathbb{R}^p : \sum_{i=1}^p x_i^2 \leq 1 \right\}$ 时, 设超球体内嵌正多面体的顶点个数为 n , 并记为 $\mathbf{x}_1, \dots, \mathbf{x}_n$. 记

$$U_n = \begin{Bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{Bmatrix}.$$

- 则当 $n > p$ 时, 不管是否存在截距项 β_0 , U_n 都是多元一次线性回归模型的 D 最优设计.
- 由于超球体内嵌正多面体有无穷个, 而且顶点个数只要大于 p 即可, 因此多元线性模型的离散 D 最优设计不唯一.

例 (多元一次线性回归模型 cont.)

当试验区域为超立方体 $\mathcal{X} = \{\mathbf{x} \in \mathbb{R}^p : |x_i| \leq 1, i = 1, 2, \dots, p\}$ 时, 设 $S = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_s : \mathbf{v}_i \in \mathbb{R}^p, i = 1, 2, \dots, s\}$ 表示超立方体的全体顶点. 则

- 离散 D 最优设计为

$$\xi_{n,S} = \begin{Bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_s \\ \frac{1}{s} & \frac{1}{s} & \cdots & \frac{1}{s} \end{Bmatrix}.$$

- 试验次数为 n 的精确 D 最优设计为

$$\xi_{n,S} = \begin{Bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_s \\ \frac{n_1}{n} & \frac{n_2}{n} & \cdots & \frac{n_s}{n} \end{Bmatrix}, \quad \max_{i,j} |n_i - n_j| \leq 1, \quad \sum_{i=1}^s n_i = n.$$

例 (多元二次线性回归)

考虑包含 p 个因子的二阶线性回归模型

$$y = \beta_0 + \sum_{i=1}^p \beta_j x_j + \sum_{1 \leq i \leq j \leq p} \beta_{ij} x_i x_j + \varepsilon.$$

当试验区域为超球体时, 截距项会影响 D 最优设计.

- 当截距项不为 0 时, D 最优设计为: 中心点权重为 $1/[(p+1)(p+2)]$, 其余权重均匀分布在超球体的球面上;
- 当截距项为 0 时, D 最优设计为超球体球面上的均匀分布, 不包括中心点.

思考

将一幅画固定在墙上, 至少需要几颗钉子? 如果给三颗钉子, 应该如何钉? 给四颗呢?

课堂小结

- 设计的信息矩阵;
- 最优设计的概念;
- 最优设计的字母序准则: A 准则、 C 准则、 D 准则、 G 准则.

3.3 最优回归设计

3.3.1 设计的信息矩阵

3.3.2 优良性准则

3.3.3 等价性定理

3.3.4 D 最优设计的迭代求解

设函数 $f: \mathbb{R}^p \mapsto \mathbb{R}$. $f(\boldsymbol{x})$ 在点 $\boldsymbol{x} \in \mathbb{R}^p$ 处沿着方向 $\boldsymbol{h} \in \mathbb{R}^p$ 的**方向导数**的定义为

$$\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{h}} = \lim_{\alpha \rightarrow 0^+} \frac{1}{\alpha} [f(\boldsymbol{x} + \alpha \boldsymbol{h}) - f(\boldsymbol{x})].$$

二元函数 $f(x_1, x_2)$ 沿着方向 $\boldsymbol{h} = (\cos \alpha, \sin \alpha)$ 的方向导数为

$$\frac{\partial f(x_1, x_2)}{\partial \boldsymbol{h}} = \frac{\partial f(x_1, x_2)}{\partial x_1} \cos \alpha + \frac{\partial f(x_1, x_2)}{\partial x_2} \sin \alpha.$$

函数极值点与方向导数的关系

- \boldsymbol{x}^* 为 f 的极小值点, 当且仅当 $\frac{\partial f(\boldsymbol{x}^*)}{\partial \boldsymbol{h}} \geq 0$ 对任意 $\boldsymbol{h} \in \mathbb{R}^p$ 都成立;
- \boldsymbol{x}^* 为 f 的极大值点, 当且仅当 $\frac{\partial f(\boldsymbol{x}^*)}{\partial \boldsymbol{h}} \leq 0$ 对任意 $\boldsymbol{h} \in \mathbb{R}^p$ 都成立.

- 假定 $\Phi : \Xi \mapsto \mathbb{R}^+$ 为凸函数, 即

$$\Phi(\alpha\xi + (1 - \alpha)\eta) \leq \alpha\Phi(\xi) + (1 - \alpha)\Phi(\eta),$$

- 要求 Φ 一阶可微. 称

$$F_{\Phi}(\xi, \eta) = \lim_{\alpha \rightarrow 0^+} \frac{1}{\alpha} [\Phi((1 - \alpha)\xi + \alpha\eta) - \Phi(\xi)].$$

为 $\Phi(\cdot)$ 在 ξ 处沿 η 方向的 F -导数.

- ξ^* 是 Φ 的最小值, 当且仅当 $F_{\Phi}(\xi^*, \eta) \geq 0$ 对任意设计 η 成立!

- 若 Φ 在 ξ 处可微, 则

$$F_{\Phi} \left(\xi, \sum w_i \eta_i \right) = \sum w_i F_{\Phi}(\xi, \eta_i),$$

其中 $\sum w_i = 1$.

- 以 δ_x 表示在点 x 处权重为 1 的设计, $w(x)$ 表示设计 η 在点 x 处的权重则

$$F_{\Phi}(\xi, \eta) = \sum_x w(x) F_{\Phi}(\xi, \delta_x).$$

- 称 $\phi(x, \xi) := F_{\Phi}(\xi, \delta_x)$ 为敏感性函数.

定理 (等价性定理)

如果 Φ 为凸函数, 且在 Ξ 中的所有点处可微, 则下列命题等价:

- (1) ξ^* 是 Φ -最优设计;
- (2) 对任意 $x \in \mathcal{X}$, 都有 $\phi(x, \xi^*) \geq 0$;
- (3) $\phi(x, \xi^*)$ 在 ξ^* 的所有支撑点上都取最小值, 且最小值为 0.

- 应用到具体准则时, 需要验证其凸性和可微性, 并给出敏感性函数.

定理 (D 最优设计的等价性定理)

对于 D 最优设计而言, $-\log \det[\mathbf{M}(\xi)]$ 作为 Ξ 上的函数是一个凹函数, $\phi_D(\mathbf{x}, \xi) = m - d(\mathbf{x}, \xi)$, 且以下三个结论等价:

- (1) ξ^* 是 D 最优设计, 即 $\det(\mathbf{M}(\xi^*)) = \max_{\xi} \det(\mathbf{M}(\xi))$;
- (2) ξ^* 是 G 最优设计, 即 $\max_{\mathbf{x}} d(\mathbf{x}, \xi^*) = \min_{\xi} \max_{\mathbf{x}} d(\mathbf{x}, \xi)$;
- (3) ξ^* 满足 $\max_{\mathbf{x}} d(\mathbf{x}, \xi^*) = m$, 且 $d(\mathbf{x}, \xi^*)$ 在 ξ^* 的任一支撑点达到最大.

此外, 所有 D 最优设计有相同的信息矩阵, D 最优设计的线性组合还是 D 最优设计.

3.3 最优回归设计

3.3.1 设计的信息矩阵

3.3.2 优良性准则

3.3.3 等价性定理

3.3.4 D 最优设计的迭代求解

- 最优设计一般不存在解析表达式, 只能数值求解.
- 在等价性定理的基础上, 前苏联统计学家 Fedorov 给出了一个构造 D 最优设计的迭代算法.
- (Kernighan and Lin, 1970) 提出构造精确 D -最优设计 KL 算法.

Federov 迭代算法

Step 1 构造非奇异的初始设计 $\xi_0 = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}$.

Step 2 对 $k = 0, 1, \dots$, 求

$$\begin{cases} \mathbf{x}_{n+k+1} = \arg \max_{\mathbf{x} \in \mathcal{X}} d(\mathbf{x}, \xi_k), \\ \alpha_k = \arg \max_{\alpha \in [0,1]} \det \mathbf{M}(\xi_{k+1}(\alpha)). \end{cases}$$

这里 $\xi_{k+1}(\alpha) = (1 - \alpha)\xi_k + \alpha\delta_{\mathbf{x}_{n+k+1}}$. 可以证明

$$\alpha_k = \frac{d(\mathbf{x}_{n+k+1}, \xi_k) - m}{[d(\mathbf{x}_{n+k+1}, \xi_k) - 1]m}.$$

● 当 $k \rightarrow \infty$ 时, 序列 ξ_k 收敛到 D 最优设计.

Federov 迭代算法

Step 1 构造非奇异的初始设计 $\xi_0 = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}$.

Step 2 对 $k = 0, 1, \dots$, 求

$$\begin{cases} \mathbf{x}_{n+k+1} = \arg \max_{\mathbf{x} \in \mathcal{X}} d(\mathbf{x}, \xi_k), \\ \alpha_k = \arg \max_{\alpha \in [0,1]} \det \mathbf{M}(\xi_{k+1}(\alpha)). \end{cases}$$

这里 $\xi_{k+1}(\alpha) = (1 - \alpha)\xi_k + \alpha\delta_{\mathbf{x}_{n+k+1}}$. 可以证明

$$\alpha_k = \frac{d(\mathbf{x}_{n+k+1}, \xi_k) - m}{[d(\mathbf{x}_{n+k+1}, \xi_k) - 1]m}.$$

• 当 $k \rightarrow \infty$ 时, 序列 ξ_k 收敛到 D 最优设计.

构造精确设计的 KL 算法

- (1) 产生试验次数为 n_0 的确定性设计 ξ_0 .
- 由部分希望试验的点和部分随机抽取的点组成.

构造精确设计的 KL 算法

- (1) 产生试验次数为 n_0 的确定性设计 ξ_0 .
- (2) 添加设计点 ($n_0 < n$) 或删除设计点 ($n_0 > n$), 得到试验次数为 n 的初始设计 η_0 .
 - 前进法: 添加使设计 ξ_i 的标准化方差达到最大的点,

$$d(\mathbf{x}_l, \xi_i) = \max_{\mathbf{x} \in \mathcal{X}} d(\mathbf{x}, \xi_i).$$

当 $M(\xi_i)$ 不可逆时, 以 $M(\xi_i) + \varepsilon I$ 来代替, 其中 $10^{-6} < \varepsilon < 10^{-4}$.

- 后退法: 删除使设计 ξ_i 的标准化方差达到最小的点,

$$d(\mathbf{x}_k, \xi_{i-1} \setminus \mathbf{x}_k) = \min_{\mathbf{x} \in \xi_{i-1}} d(\mathbf{x}, \xi_{i-1} \setminus \{\mathbf{x}\}).$$

构造精确设计的 KL 算法

- (1) 产生试验次数为 n_0 的确定性设计 ξ_0 .
- (2) 添加设计点 ($n_0 < n$) 或删除设计点 ($n_0 > n$), 得到试验次数为 n 的初始设计 η_0 .
- (3) 对初始设计 η_0 的点进行替换, 直至收敛.
 - 替换的目的是使得信息矩阵的行列式增大, 由标准化方差的变动来实现.

总结

- ① 线性模型的信息矩阵;
- ② 最优设计的思想与概念;
- ③ 最优设计的常用准则;
- ④ 等价性定理;
- ⑤ 线性模型最优设计的求解算法.